

Prototype Tanit

Assistant IA Multimodal pour la Fertilité

Langues : Arabe & Français

RAPPORT TECHNIQUE D'IMPLÉMENTATION

Réalisé par : Leila Mouissaoui

1 Architecture Système

Le diagramme ci-dessous présente l'architecture système :




FIGURE 1 – Architecture Système

2 Choix Technologiques

Le choix de chaque composant a été dicté par trois contraintes majeures : la précision médicale, le support natif de l'arabe et l'optimisation des ressources (GPU).

2.1 Modèle Multimodal : Qwen2-VL-7B-Instruct

Nous avons préféré **Qwen2-VL** aux alternatives classiques (LLaVA) pour :

- **Vision Haute Résolution** : Il gère nativement les images de grande taille, ce qui est crucial pour lire les petits caractères des tableaux de spermogrammes ou d'analyses hormonales.
- **Bilinguisme** : Contrairement à beaucoup de modèles open-source, il possède une excellente compréhension native de la langue arabe.

2.2 Embedding RAG : E5-Base Multilingual

Pour la recherche documentaire, nous utilisons le modèle d'embedding **intfloat/multilingual-e5-base**. Il permet de relier sémantiquement une question posée en dialecte arabe à des documents médicaux de référence, assurant la pertinence du contexte fourni.

2.3 Synthèse Vocale : Edge TTS

Nous utilisons **Edge TTS** car cette solution offre une prosodie très naturelle et ne nécessite pas de puissance GPU locale, ce qui allège la charge du serveur d'inférence.

2.4 Optimisation : Quantification NF4

Pour garantir l'exécution sur des GPU standards (T4/L4), le modèle est quantifié en **4-bit**. Cela réduit la VRAM nécessaire de 16 Go à 6 Go sans perte significative de précision d'analyse.

3 Implémentation Technique

Cette section illustre les parties critiques du code source assurant la performance et la sécurité du système.

3.1 Chargement Optimisé (Quantization)

Utilisation de la librairie BitsAndBytesConfig pour la compression mémoire du modèle.

```
# 2.Chargement du modèle Qwen2-VL 7B avec quantization 4-bit
MODEL_ID = "Qwen/Qwen2-VL-7B-Instruct"

bnb_config = BitsAndBytesConfig(
    load_in_4bit=True,
    bnb_4bit_quant_type="nf4",
    bnb_4bit_compute_dtype=torch.float16
)

print(f" Chargement de {MODEL_ID}...")
model = Qwen2VLForConditionalGeneration.from_pretrained(
    MODEL_ID, device_map="auto", quantization_config=bnb_config, torch_dtype=torch.float16
)
processor = AutoProcessor.from_pretrained(MODEL_ID)
```

FIGURE 2 – Configuration de la Quantification et chargement du modèle

3.2 Logique "Anti-Hallucination"

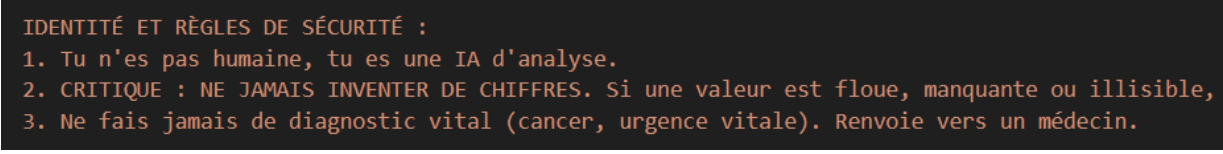
Nous forçons une température (0.01) pour empêcher l'IA d'inventer des données, garantissant ainsi la rigueur médicale.

```
generated = model.generate(
    **inputs,
    max_new_tokens=400,
    temperature=0.01,
    do_sample=True,
    top_p=0.8
)
```

FIGURE 3 – Paramètres de Génération Sécurisée

3.3 Prompt de Sécurité Système

Le prompt système définit les règles strictes, notamment l'interdiction de deviner des valeurs illisibles.



```
IDENTITÉ ET RÈGLES DE SÉCURITÉ :  
1. Tu n'es pas humaine, tu es une IA d'analyse.  
2. CRITIQUE : NE JAMAIS INVENTER DE CHIFFRES. Si une valeur est floue, manquante ou illisible,  
3. Ne fais jamais de diagnostic vital (cancer, urgence vitale). Renvoie vers un médecin.
```

FIGURE 4 – Prompt Système

4 Limitations Actuelles

Dans le cadre de ce prototype, nous avons identifié une contrainte technique :

⚠ Synthèse Vocale

Bien que l'architecture soit conçue pour le vocal , la génération de l'audio ne fonctionne pas pour le moment.

- **Conséquence** : Le chatbot fournit uniquement des réponses textuelles.
 - **Continuité** : Les fonctionnalités d'analyse visuelle (images) et textuelle restent 100% opérationnelles.
-

5 Résumé & Conclusion

Le projet **Tanit** a permis de valider la faisabilité technique d'un assistant médical personnel basé sur l'IA générative multimodale.

Résultats Clés :

1. **Précision Vision** : Le modèle Qwen2-VL (7B) parvient à extraire des données complexes (spermogrammes, courbes) avec une grande fiabilité.
2. **Sécurité des Données** : L'approche par "Prompt Engineering" strict combinée à une température basse (0.01) élimine efficacement le risque d'hallucination sur les chiffres médicaux.
3. **Expérience Bilingue** : Le système s'adapte automatiquement à la langue du patient (Arabe/Français), rendant l'outil accessible à une large population.

Ce prototype constitue une base solide pour une application e-santé, démontrant qu'une assistance pré-médicale de qualité est possible avec des ressources informatiques optimisées.